

Описание

В рамках проекта ты познакомишься с обработкой данных на примере Yandex DataLens.

Set up a specific runner manually

Шаг 1: Установите **Gitlab Runner** и убедитесь, что он запущен.

Шаг 2: Зарегистрируйте участника забега

Проект 1. Data-driven подход

Что такое data-driven подход?

Data-driven (англ. «управляемый данными») — это подход к управлению, который основывается на собираемых данных. Он используется для построения бизнес-модели или маркетинговой стратегии, при составлении плана продаж, в программировании и даже дизайне. Проще говоря, это способ принятия решений, при котором команда опирается не на мнение или интуицию, а на данные: цифры, метрики, результаты исследований, экспериментов и аналитики.

Кто такой аналитик данных?

Чтобы решения действительно опирались на факты, в команде должен быть специалист, который умеет превращать сырые цифры в понятные выводы. Это как раз работа аналитика данных.

В отличие от специалистов, которые занимаются разработкой и внедрением систем на основе искусственного интеллекта (например, ML-исследователь, Data Scientist, ML-инженер), аналитики данных менее чувствительны к отрасли или размерам компании, ее готовности внедрять инновации и даже вычислительным мощностям. Главное — это желание и готовность бизнеса получать качественные данные.

Для этого аналитику данных необходимы следующие навыки:

- Задавать вопросы бизнесу и помогать сводить к понятным и вычисляемым показателям;
- Ориентироваться, какие данные потребуются для вычисления этих показателей и уметь доставать их из базы данных, из открытых источников в интернете и т. д.;
- Вычислять показатели, которые были определены ранее, проводить статистические исследования;
- Уметь понятно сформулировать выводы и визуализировать результаты анализа;
- Ставить аналитику на поток, если появляются повторяющиеся типовые задачи.

Знакомство с инструментом Yandex DataLens

Аналитику данных важно уметь не только правильно произвести расчеты и собрать аналитику, а также уметь оформлять результаты своей работы в виде графиков и схем. Для этого на рынке представлено множество инструментов, одним из наиболее популярных является Yandex DataLens.

Yandex DataLens — визуальный инструмент, который позволяет быстро строить интерактивные отчеты и графики.

В DataLens можно построить различные графики, ниже перечислены типы графиков, которые встречаются чаще всего:

№	Тип графика	Для чего нужен	Пример
1	Линейный график	Отображает изменение одного или нескольких показателей на отрезке времени.	Рост числа активных пользователей мобильного приложения по месяцам или динамика среднего чека по неделям.
2	Столбчатый график	Отображает значения одного показателя или нескольких показателей по периодам времени или по категориям. Чем выше столбец, тем больше его значение.	Количество заказов в разных городах или рейтинг факультетов по числу учащихся.
3	Круговая диаграмма	Отображает отношение между категориями при помощи сегментов круга. Площадь всего круга равна 100% и соответствует сумме всех категорий.	Доля пользователей Android и iOS, или распределение способов оплаты (карта/СБП/наличные).
4	Диаграмма с областями	Показывает изменение показателя во времени. При показе нескольких категорий данных они накладываются друг на друга сверху или в проекции, в зависимости от настройки.	Как росло количество заказов в сумме каждый день или как распределяется нагрузка на серверы по времени суток.
5	Точечная диаграмма	Показывает отношение между двумя величинами. Всегда есть две оси: набор значений одной величины представлен вдоль горизонтальной оси, а другой — вдоль вертикальной.	Зависимость суммы заказа от возраста пользователя или зависимость частоты заказов от суммы чека.
6	Тепловая карта	Показывает плотность распределения точек. Области окрашиваются градиентом от зеленого цвета к красному: чем больше точек сгруппированы в области, тем ближе к красному будет ее цвет.	Активность студентов по часам или частота ошибок в приложении по типам устройств.
7	Индикатор	Индикатор отражает значение одного ключевого показателя.	Средний чек 780 рублей или конверсия в оплату 12,3%.

DataLens состоит из цепочки, которая ведет от сырых данных к визуальному отчету:


- **Воркбук** — рабочее пространство, где хранятся датасеты, чарты, дашборды.

- **Подключение** — это то, откуда берутся данные, на этом этапе необходимо подключиться к источнику данных, это может быть таблица, загруженный файл или подключение к базе данных.
- **Датасет** — часть данных из источника, которая была выгружена для последующей обработки.
- **Чарт** — это визуализация конкретных данных из источника данных в виде диаграммы или графика.
- **Дашборд** — набор чартов, текстовое описание графиков.

Работа с инструментом строится следующим образом: создание воркбука → подключение к источнику данных → создание датасета → создание чарта → сборка дашборда. При необходимости всегда можно обратиться к официальной документации Yandex DataLens.

Интерфейс Yandex DataLens

Интерфейс Yandex DataLens интуитивно понятен. На главной странице в левой панели меню ты можешь увидеть все составляющие цепочки. Пройди все этапы последовательно, начиная с создания воркбука.



На этапе создания чарта необходимо выбрать тип графика из выпадающего списка. Чтобы создать чарт, нужно перетащить измерения в ось X, Y и другие доступные категории полей.

При необходимости можно менять настройки визуализации чарта:

- В поле «Сортировка» изменять сортировку по убыванию и возрастанию.
- Если у поля есть шестеренка, можно изменить формат числа, добавить проценты, валюту, изменить количество знаков после запятой и другое.
- У некоторых полей, таких как, например, «Дата», можно корректировать формат отображения.
- Менять агрегацию или, простыми словами, объединить много строк данных в одно значение.

Агрегации

Например, есть таблица с 500 заказами, в ней каждая строка — один заказ, но нет необходимости видеть все 500 строк, нужен только итог, например:

- Сколько всего заказов было,
- Сколько денег заработали,

- Какой средний чек,
- Какая максимальная цена.

Для этого и существует агрегация — чтобы превратить много строк в одно осмысленное значение.

В Yandex DataLens доступны следующие виды агрегации данных:

- **SUM** — складывает сумму всех значений. Пример: сколько всего денег заработали?
- **AVG** — считает среднее значение. Пример: какой средний чек?
- **COUNT** — считает количество строк. Пример: сколько заказов было?
- **COUNTD** — считает уникальные значения. Пример: сколько было уникальных клиентов?
- **MAX** — находит самое большое значение. Пример: какой самый дорогой заказ?
- **MIN** — находит самое маленькое значение. Пример: какая минимальная цена?

Агрегация меняется у поля при переходе в значок $f(x)$: выбери нужный вариант агрегации из списка и внеси его туда.

Практические задания

В этом проекте ты познакомишься с Yandex DataLens на примере данных об авиаперелетах одного путешественника. Ниже представлено описание датасета, с которым тебе предстоит работать:

- **'NUM'** — порядковый номер записи;
- **'DATE'** — дата вылета;
- **'FLIGHT'** — номер рейса;
- **'REG'** — номер рейса партнера;
- **'FROM'/'TO'** — код аэропорта вылета/прилета;
- **'DIST'** — расстояние в пути, км;
- **'DEP'/'ARR'** — время вылета/прибытия;
- **'AIRLINE'** — код авиакомпании;
- **'AIRCRAFT'** — модель самолета;
- **'SEAT'** — выбор места на борту (W (window) — у окна, M (middle) — в середине, A (aisle) — у прохода);
- **'TICKET'** — тариф (эконом/бизнес);
- **'REASON'** — цель поездки (B (business) — работа, L (leisure) — отдых);
- **'iata_code'** — код аэропорта вылета;
- **'name_rus'/'name_eng'** — название аэропорта вылета на русском/английском;
- **'city_rus'/'city_eng'** — город вылета на русском/английском; **'country_rus'** — страна;

Задание 1. Создаем подключение и датасет

1. Зарегистрируйся в Yandex DataLens datalens.yandex.ru.
2. Скачай файл `da_project01_flights_statistic_aero.csv` из папки `datasets`.
3. В меню «Коллекции и воркбуки» создай воркбук и дай ему название.
4. **Создание подключения** в воркбуке:
 - Перейди в «Создать подключение», выбери «Файл» и в качестве источника. Выбери скачанный ранее `da_project01_flights_statistic_aero.csv`. Укажи название своего подключения.

- Выбери «Показывать заголовки столбцов» — тогда названия столбцов подтянутся из таблицы автоматически.
- Сохрани скриншот с подключением и назови его connection.

5. **Создание датасета** в воркбуке:

- Перейди в «Создать датасет» и добавь ранее созданное подключение. Укажи название своего датасета.
- Сохрани скриншот созданного датасета и назови его dataset.

6. Загрузи файл в папку src ветки develop.

Задание 2. Создаем графики

На основе датасета из прошлого задания необходимо создать набор чартов (графиков):

1. **Создание чарта** в воркбуке:

- Перейди в «Создать чарт», выбери «Чарт в Wizard».
- Выбери ранее созданный датасет.

2. Из выпадающего списка выбери необходимый тип графика и задай измерение «Общая дистанция» — 'DIST'. По итогу должна отобразиться сумма пути в км. Сохрани чарт под названием distance.

3. Создай круговую диаграмму и задай измерение «Место в самолете» — 'SEAT'. В результате на диаграмме должен отобразиться % по выбранному месту (у окна, в середине или у прохода). Сохрани чарт под названием seat.

4. Создай по такому же принципу линейчатую диаграмму и задай измерение «Аэропорт вылета». На диаграмму необходимо вывести количество вылетов по аэропортам, а строки необходимо отсортировать по убыванию количества вылетов (сверху — самый частый аэропорт). Чтобы выполнить задание, необходимо воспользоваться агрегатами. Сохрани чарт под названием departure.

5. Загрузи скриншот в папку src ветки develop.

Задание 3. Создаем дашборд

В этом задании необходимо создать дашборд из графиков, полученных ранее.

1. Создай дашборд, добавь на него заголовок «Основное задание».
2. Подпиши каждый график.
3. Под графиками напиши, какие выводы можно сделать.
4. Сделай скриншот дашборда и назови da_project01_dashboard.pdf.
5. Загрузи файл в папку src ветки develop.