

Проект 3. Когнитивные искажения

В этом проекте ты познакомишься с когнитивными искажениями — типичными ошибками мышления, которые возникают при работе с большими данными и при принятии решений.

Содержание

- [Глава 1](#)
 - [Когнитивные искажения в работе аналитика](#)
 - [Типичные аналитические ошибки](#)
- [Глава 2](#)
 - [Когнитивные искажения в Yandex DataLens](#)
 - [Флаги в Yandex DataLens](#)
 - [Практические задания](#)
 - [Задание 1. Подготовка датасета](#)
 - [Задание 2. Создаём графики](#)
 - [Задание 3. Интерпретация данных](#)

Глава 1

Когнитивные искажения в работе аналитика

Когнитивные искажения — это излишняя субъективность в анализе информации, нелогичные, предвзятые, поспешные выводы.

На текущий момент насчитывается несколько десятков разных когнитивных искажений. В работе аналитика когнитивные искажения особенно опасны, так как данные часто выглядят объективными. Даже при наличии точных чисел и корректных расчетов можно прийти к неверным выводам, если не учитывать ограничения данных и особенности их представления.

Вот некоторые из них:

- **Ошибка выжившего** — это когда берут в расчет только известные факты и пренебрегают неизвестными.
- **Подтверждающее искажение** — это склонность искать и замечать только те данные, которые подтверждают уже существующую точку зрения, и игнорировать противоречащие факты.
- **Якорение** — это чрезмерная зависимость от первого увиденного значения или показателя.
- **Иллюзия закономерности** — это поиск закономерностей там, где на самом деле есть только случайность.
- **Смешение корреляции и причинности** — это предположение о том, что если два показателя меняются вместе, один обязательно вызывает другой.
- **Ошибка доступности** — это оценка ситуации на основе самых заметных, недавних или эмоциональных примеров.

Рассмотрим подробнее одно из самых распространенных искажений: *ошибка выжившего*. В пример к данному искажению можно привести открытие математика **Абрахама Вальда** во время Второй мировой войны. Американская армия теряла много самолетов в боях. Чтобы решить проблему и уменьшить потери, командование поставило перед Вальдом задачу — придумать, как укрепить конструкцию самолета. Полностью забронировать машины было нельзя, иначе они бы просто не полетели, поэтому нужно было определить самые уязвимые места. Военные инженеры изучили повреждения машин, вернувшихся с поля боя, и предположили, что нужно укреплять наиболее поврежденные части. Однако Абрахам Вальд отметил, что если самолет смог вернуться на базу, то попадания в эти части не критические. Важнее обратить внимание на те повреждения, с которыми самолеты не возвращались. То есть бронировать нужно те места, где у «выживших» машин не было пробоин. Это помогло снизить потери американской авиации и сохранить жизни многих летчиков.

Часто бизнес обращается к анализу данных как раз в попытках исключить влияние когнитивных искажений. Однако и аналитики без должной подготовки сами могут быть подвержены когнитивным искажениям. Например, аналитик может неосознанно подгонять анализ под ожидаемый результат, делать выводы по неполным данным или видеть устойчивые паттерны там, где их нет.

Важно помнить, что визуализация — это лишь способ представления данных, а не готовый вывод. Любой график требует дополнительной проверки и интерпретации, а аналитик — это не просто исполнитель, его задача — проверять все на каждом этапе, а именно:

- Задаваться вопросом, какие данные отсутствуют;
- Проверять альтернативные объяснения;
- Использовать разные метрики;
- Разделять наблюдения и интерпретацию;
- Помнить, что визуализация — это начало анализа, а не его конец.

Типичные аналитические ошибки

Распределения и частотность данных

Аналитику важно понимать как распределены данные, а также их частотность.

Частность — количество наблюдений в каждом диапазоне значений.

Без этого можно сделать выводы и принять их за закономерность.

Например, если определенное значение показателя встречается всего в нескольких наблюдениях, любые выводы на его основе будут нестабильными. И наоборот: зоны с высокой частотностью отражают типичное поведение данных и заслуживают большего доверия. Игнорирование частотности может привести к иллюзии закономерности.

Медиана и влияние выбросов

В данных часто бывают выбросы.

Выбросы — это значения, которые сильно отличаются от большинства.

Для описания типичных значений часто используют не среднее, а медиану — значение, которое делит выборку пополам. Медиана менее чувствительна к выбросам, чем среднее значение, но и она все

равно может смещаться при определенных обстоятельствах. Если в выборке присутствуют массовые выбросы, они могут сформировать ложное представление.

Например, время доставки по большинству заказов 25-40 минут, но иногда бывают сбои и доставка увеличивается до 2 часов. Среднее время может стать 60–90 минут и создаст впечатление, что доставка долгая. Медиана покажет время ближе к реальности — 32 минуты. Но если сбои стали массовыми (например, 20% заказов задерживаются), даже медиана начнет расти.

Якорение на удобных значениях

Одной из распространенных причин искажения данных является использование удобных или округленных значений. Такие значения часто возникают из-за автозаполнения форм или приблизительных оценок. Когда аналитик видит большое количество одинаковых значений, возникает эффект якорения.

Эффект якорения — большое количество одинаковых значений начинают восприниматься как реальные.

Например, когда люди указывают свой доход, они ставят круглое число — 50000 или 100000. На графике эти значения начинают становиться самыми популярными доходами, а на деле — люди просто ставят круглое число, потому что не видят смысла писать с высокой точностью.

Агрегация и потеря информации

При построении дашбордов аналитик почти всегда использует агрегации: средние, медианы, суммы. Агрегация упрощает данные и делает их удобными для восприятия, но при этом скрывает детали.

Например, линия на графике может выглядеть устойчивой и гладкой, даже если за отдельными точками скрываются небольшие группы наблюдений. В таких случаях визуальная форма графика может вводить в заблуждение. Поэтому при анализе агрегированных показателей важно всегда учитывать размер выборки и проверять, не обоснованы ли выводы на малом числе наблюдений.

Например, средний чек в магазине 1520 рублей. На первый взгляд кажется, что это плохо. Но внутри есть две группы: 90% заказов — 800 ₽ и 10% заказов — 8000 ₽.

Размер выборки и влияние на надежность выводов

Надежность выводов зависит от числа наблюдений. Обычно в зонах с высокой частотностью показатели устойчивы и заслуживают доверия. А там, где данных мало, значения нестабильны.

Например, пост 1 в социальной сети увидели 1000 человек, лайк поставили 100 человек — это 10%. Пост В увидели 10 человек, лайк поставили 1 — это тоже 10%.

Наблюдение и интерпретация

Аналитик должен разделять два этапа работы с данными: наблюдение и интерпретацию.

Наблюдение — это то, что непосредственно видно на графике или в таблице.

Интерпретация — это выводы, которые мы делаем на основе этих наблюдений.

Смешение этих этапов часто приводит к искажению. Наблюдение должно быть нейтрально, без объяснений причин и последствий.

Глава 2

Когнитивные искажения в Yandex DataLens

Наличие данных и хорошо построенных графиков не гарантирует объективных и правильных выводов. Человек, который анализирует данные, всегда остается частью процесса принятия решений и может быть подвержен когнитивным искажениям.

Каждый дашборд — это результат решений, которые принимает аналитик:

- Какие данные использовать;
- Какие поля и метрики выбрать;
- Какую агрегацию применить;
- Какие фильтры/селекторы включить;
- Какой тип графика построить.

Каждое из этих решений может быть искажено, поэтому важно научиться осознанно проверять собственные выводы.

Флаги в Yandex DataLens

При работе с данными аналитик часто сталкивается с ситуацией, когда нужно разделить данные на группы по определенному признаку. Для этого используются **флаги**.

Флаг — это вычисляемое поле, которое принимает одно из двух значений:

- 1 — условие выполнено;
- 0 — условие не выполнено.

Проще говоря, флаг отвечает на вопрос: *относится этот объект к нужной нам категории или нет?*

Флаги решают сразу несколько важных задач в аналитике:

- Упрощают фильтрацию данных. С флагами легко включать и выключать определенные группы объектов с помощью фильтров. Например, можно быстро исключить данные с подозрительными значениями.
- Помогают считать доли. Если флаг принимает значения 0 и 1, то его среднее значение показывает долю объектов, для которых условие выполнено.
- Делают анализ прозрачным. Флаг явно фиксирует правило, по которому данные считаются «особыми». Это лучше, чем каждый раз помнить сложные условия в голове.
- Помогают бороться с когнитивными искажениями. Флаги позволяют формализовать подозрения аналитика и проверить их на данных, а не доверять интуиции. Флаги создаются с помощью вычисляемых полей и функции IF.

Синтаксис:

```
IF(  
условие,  
1,  
0  
)
```

Практические задания

В этом задании ты поработаешь с когнитивными искажениями в Yandex DataLens на примере данных ЦИАН о недвижимости в Москве. Ниже представлено описание датасета, с которым тебе предстоит работать:

- **metro** — ближайшая станция метро;
- **price** — цена (руб.);
- **way** — способ добраться до метро (walk/transport);
- **minutes** — время до метро (в минутах);
- **views** — просмотры объявления;
- **provider** — кто разместил объявление (встречаются значения с пробелами / разным написанием);
- **fee_percent** — комиссия, %;
- **storey** — этаж квартиры;
- **storeys** — этажность дома;
- **living_area** — жилая площадь;
- **kitchen_area** — площадь кухни;
- **total_area** — общая площадь;
- **rooms** — количество комнат.

Задание 1. Подготовка датасета

- Скачай файл *da_project03_data* из папки datasets.
- В меню «Коллекции и воркбуки» создай воркбук и дай ему название *Project_3*. С ранее скачанным файлом создай подключение.
- При создании датасета создай следующие вычисляемые поля:
 - Поле *price_per_sqm*, что будет отражать цену за м², используй формулу: цена (руб.) / общая площадь.
 - Создай флаг *is_placeholder_64*. Для этого используй функцию IF с условием, что общая площадь = 64 или жилая площадь = 64 или площадь кухни = 64.
 - Создай флаг *views_group* для определения высокого спроса, используй функцию IF от просмотров объявлений ≥ 300 , «Высокий интерес», «Обычный интерес».
- Сохрани скриншот созданного датасета и назови его dataset.
- Загрузи файл в папку src ветки develop.

Задание 2. Создаём графики

- Построй диаграммы и результаты округли до целого.
- Построй комбинированную диаграмму с двумя кривыми.

- Выведи зависимость медианной цены за м² от удаленности до метро (за X возьмем минуты).
- Построй количество объявлений для каждой точки из предыдущей кривой (за X возьмем минуты).
- Сделай индикатор доли объявлений, которая приходится на квартиры площадью 64 квадратных метра `AVG is_placeholder_64`, выведи в %.
- Построй диаграмму площади по частоте встречаемости (y — количество объявлений, x — жилая площадь).
- Сделай с помощью медианы индикатор распределения общей площади до очистки выбросов.
- Построй диаграмму распределения числа объявлений по площади.
- Сделай с помощью медианы индикатор распределения общей площади после очистки выбросов.
 - Добавь фильтр `is_placeholder_64` и выбери значение 0.
- Сохрани скриншоты пяти графиков и дай им названия.
- Загрузи файлы в папку `src` ветки `develop`.

Задание 3. Интерпретация данных

Ответь на вопросы в любом текстовом редакторе:

- Можно ли по этому графику утверждать, что чем дальше от метро, тем дешевле жилье?
- В каких зонах графика выводы наиболее надежны, а в каких наименее надежны? Почему?
- Почему резкие пики и провалы цены на графике необязательно отражают реальные рыночные закономерности?
- Какую типичную ошибку аналитика можно совершить, если смотреть только на синюю линию и игнорировать красную?
- Сформулируй вывод, есть ли зависимость между удаленностью до метро и ценой за квадратный метр.
- Как изменилась медиана после очистки данных и почему? Какое значение теперь имеет медиана?
- Какой вывод можно сделать на основании графиков распределения площади по частотности и числа объявлений по площади?

Сохрани документ с ответами и назови его `interpretation`. Загрузи файл в папку `src` ветки `develop`.